Mentee: Yovina Silvia Mentor: Bilal Benefit



TASK 3 - Replication + Sharding

1. Jelaskan perbedaan antara replication dan sharding

a. Replication:

- Definisi: Replication adalah proses menduplikasi data dari satu database ke database lain untuk meningkatkan ketersediaan dan keandalan data.
- **Tujuan:** Tujuannya adalah untuk memastikan bahwa data tetap tersedia dan dapat diakses meskipun ada kegagalan pada salah satu node. Replication juga dapat digunakan untuk load balancing pada aplikasi yang memerlukan akses baca tinggi.
- Karakteristik:
 - Meningkatkan ketersediaan data.
 - Menggunakan salinan data yang sama di beberapa node.
 - Memungkinkan failover dan pemulihan bencana.
- o **Contoh Penggunaan:** Digunakan pada sistem yang memerlukan toleransi kesalahan tinggi dan ketersediaan data yang sangat baik, seperti dalam aplikasi perbankan atau e-commerce.

b. Sharding:

- o **Definisi:** Sharding adalah teknik membagi data besar menjadi beberapa fragmen atau "shards" yang didistribusikan di beberapa database atau server.
- o **Tujuan:** Tujuannya adalah untuk meningkatkan kinerja dengan mendistribusikan beban kerja dan kapasitas penyimpanan di beberapa node.
- Karakteristik:
 - Meningkatkan kinerja dan skalabilitas.
 - Data dipecah menjadi beberapa bagian berdasarkan kriteria tertentu (misalnya, range atau hash).
 - Setiap shard hanya berisi subset dari keseluruhan data.
- o **Contoh Penggunaan:** Digunakan pada sistem dengan volume data sangat besar yang memerlukan skalabilitas tinggi, seperti media sosial atau platform streaming video.

Mentee: Yovina Silvia Mentor: Bilal Benefit



2. Lakukan percobaan untuk membuat reference table + distributed table seperti pada repo https://github.com/lmmersive-DataEngineer-Resource/citus-demo

```
- Create users table (Reference Table)
CREATE TABLE users (
 user id SERIAL PRIMARY KEY,
 username TEXT NOT NULL,
 email TEXT NOT NULL UNIQUE
SELECT create reference table('users');
select * from users u
CREATE TABLE products (
 product_id SERIAL PRIMARY KEY,
 name TEXT NOT NULL,
 price NUMERIC(10, 2) NOT NULL
SELECT create reference table('products');
select * from products
INSERT INTO users (username, email) VALUES ('JohnDoe', 'john.doe@example.com'), ('JaneSmith', 'jane.smith@example.com');
 - Products
INSERT INTO products (name, price) VALUES ('Laptop', 1000.00), ('Phone', 500.00), ('Headphones', 200.00), ('Monitor', 300.00);
select * from users u
select * from products
```

- ➤ Membuat Tabel Referensi 'users'
 - CREATE TABLE users: Membuat tabel users dengan kolom-kolom berikut:

Mentee: Yovina Silvia Mentor: Bilal Benefit



- o user id SERIAL PRIMARY KEY: Pengidentifikasi unik untuk setiap pengguna, secara otomatis bertambah.
- o username TEXT NOT NULL: Nama pengguna yang tidak boleh kosong.
- o email TEXT NOT NULL UNIQUE: Email pengguna yang tidak boleh kosong dan harus unik.
- **SELECT create_reference_table('users')**: Ini adalah fungsi dari Citus untuk mengatur tabel users sebagai tabel referensi. Tabel referensi digunakan untuk menyimpan data yang sering digunakan bersama oleh beberapa shard (pecahan) dalam database yang terdistribusi.
- > Membuat Tabel Referensi 'products'
 - CREATE TABLE products: Membuat tabel products dengan kolom-kolom berikut:
 - o product id SERIAL PRIMARY KEY: Pengidentifikasi unik untuk setiap produk, secara otomatis bertambah.
 - o name TEXT NOT NULL: Nama produk yang tidak boleh kosong.
 - o price NUMERIC (10, 2) NOT NULL: Harga produk yang tidak boleh kosong, dengan format numerik dua desimal.
 - SELECT create_reference_table('products'): Fungsi ini mengatur tabel products sebagai tabel referensi.
- Memasukkan Data ke Tabel 'users' dan 'products'
 - INSERT INTO users: Menyisipkan data pengguna ke dalam tabel users.
 - o ('JohnDoe', 'john.doe@example.com'): Menambahkan pengguna dengan nama JohnDoe dan email john.doe@example.com.
 - o ('JaneSmith', 'jane.smith@example.com'): Menambahkan pengguna dengan nama JaneSmith dan email jane.smith@example.com.
- Memasukkan Data ke Tabel 'products'
 - INSERT INTO products: Menyisipkan data produk ke dalam tabel products.
 - o ('Laptop', 1000.00): Menambahkan produk Laptop dengan harga 1000.00.
 - o ('Phone', 500.00): Menambahkan produk Phone dengan harga 500.00.
 - o ('Headphones', 200.00): Menambahkan produk Headphones dengan harga 200.00.

Mentee: Yovina Silvia Mentor: Bilal Benefit



o ('Monitor', 300.00): Menambahkan produk Monitor dengan harga 300.00.

Skrip SQL ini:

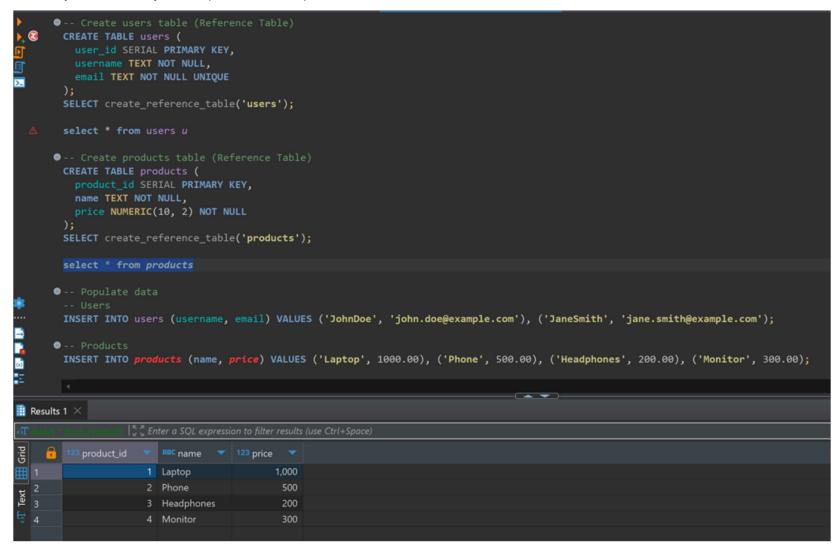
- 1. Membuat dua tabel referensi, users dan products, menggunakan PostgreSQL dan ekstensi Citus.
- 2. Mengisi tabel users dengan dua pengguna.
- 3. Mengisi tabel products dengan empat produk.
- 4. Menampilkan semua data yang telah dimasukkan ke dalam kedua tabel tersebut.

a. Tampilan dari table users (table references)

Mentee: Yovina Silvia Mentor: Bilal Benefit



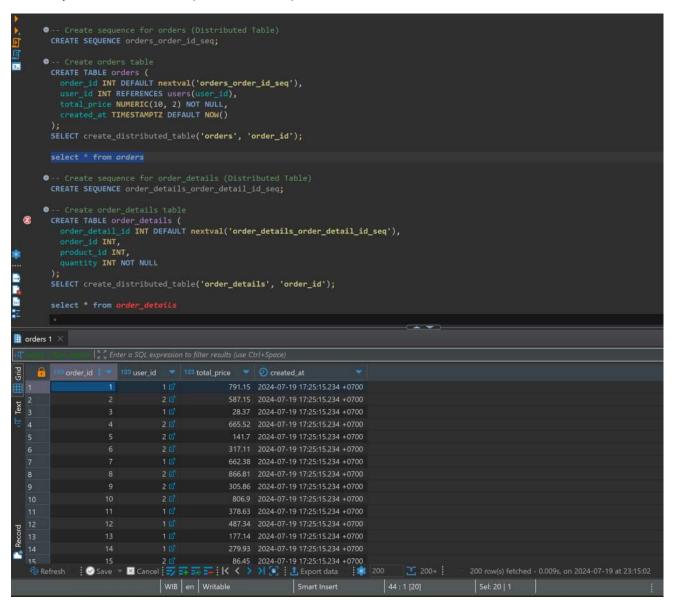
b. Tampilan dari table products (table references)



Mentee: Yovina Silvia Mentor: Bilal Benefit

alterra academy

c. Tampilan dari table orders (table distributed)



Mentee: Yovina Silvia Mentor: Bilal Benefit



```
-- Create sequence for orders (Distributed Table)

CREATE SEQUENCE orders_order_id_seq;

-- Create orders table

CREATE TABLE orders (
    order_id INT DEFAULT nextval('orders_order_id_seq'),
    user_id INT REFERENCES users(user_id),
    total_price NUMERIC(10, 2) NOT NULL,
    created_at TIMESTAMPTZ DEFAULT NOW()
);

SELECT create_distributed_table('orders', 'order_id');

select * from orders
```

Membuat Sekuens untuk Tabel 'orders'

CREATE SEQUENCE orders_order_id_seq: Membuat sekuens bernama orders_order_id_seq. Sekuens ini akan menghasilkan nilai unik yang secara otomatis bertambah untuk digunakan sebagai order id dalam tabel orders.

- Membuat Tabel 'orders'
 - CREATE TABLE orders: Membuat tabel orders dengan kolom-kolom berikut:
 - o order_id INT DEFAULT nextval('orders_order_id_seq'): Pengidentifikasi unik untuk setiap pesanan, menggunakan nilai berikutnya dari sekuens orders order id seq.
 - o user_id INT REFERENCES users (user_id): Pengidentifikasi unik pengguna yang melakukan pesanan, dengan referensi ke kolom user id di tabel users.
 - o total_price NUMERIC(10, 2) NOT NULL: Total harga pesanan yang tidak boleh kosong.
 - o created at TIMESTAMPTZ DEFAULT NOW(): Waktu pembuatan pesanan, dengan nilai default waktu saat ini.
 - SELECT create_distributed_table('orders', 'order_id'): Mengatur tabel orders sebagai tabel terdistribusi menggunakan Citus, dengan kolom distribusi order_id. Tabel terdistribusi berarti data akan dipecah dan disebarkan ke beberapa node pekerja dalam kluster Citus untuk meningkatkan kinerja.

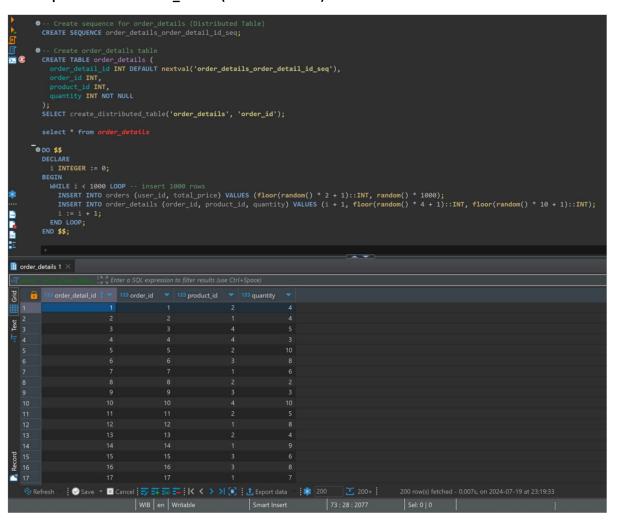
Mentee: Yovina Silvia Mentor: Bilal Benefit



Menampilkan Data dari Tabel 'orders'

SELECT * **from orders**: Menampilkan semua data dari tabel orders.

d. Tampilan dari table order_details (table distributed)



Mentee: Yovina Silvia Mentor: Bilal Benefit



```
-- Create sequence for order_details (Distributed Table)

CREATE SEQUENCE order_details_order_detail_id_seq;

-- Create order_details table

CREATE TABLE order_details (
    order_detail_id INT DEFAULT nextval('order_details_order_detail_id_seq'),
    order_id INT,
    product_id INT,
    product_id INT,
    quantity INT NOT NULL

);

SELECT create_distributed_table('order_details', 'order_id');

select * from order_details
```

Membuat Sekuens untuk Tabel 'order_details

CREATE SEQUENCE order_details_order_detail_id_seq: Membuat sekuens bernama order_details_order_detail_id_seq. Sekuens ini akan menghasilkan nilai unik yang secara otomatis bertambah untuk digunakan sebagai order_detail_id dalam tabel order details.

- Membuat Tabel 'order_details'
 - CREATE TABLE order_details: Membuat tabel order_details dengan kolom-kolom berikut:
 - o order_detail_id INT DEFAULT nextval('order_details_order_detail_id_seq'): Pengidentifikasi unik untuk setiap detail pesanan, menggunakan nilai berikutnya dari sekuens order details order detail id seq.
 - o order id INT: Pengidentifikasi unik untuk pesanan, digunakan untuk menghubungkan dengan tabel orders.
 - o product_id INT: Pengidentifikasi unik untuk produk, digunakan untuk menghubungkan dengan tabel products.
 - o quantity INT NOT NULL: Jumlah produk dalam pesanan yang tidak boleh kosong.
 - SELECT create_distributed_table('order_details', 'order_id'): Mengatur tabel order_details sebagai tabel terdistribusi menggunakan Citus, dengan kolom distribusi order id.

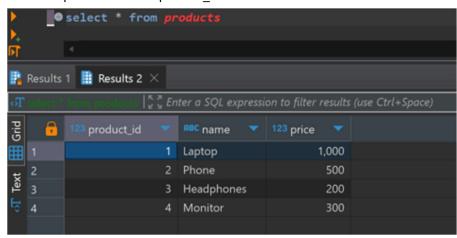
Mentee: Yovina Silvia Mentor: Bilal Benefit



Menampilkan Data dari Tabel 'order_details'

SELECT * from order_details: Menampilkan semua data dari tabel order details.

- 3. Di node/worker mana saja product "Headphone" tersimpan? Tunjukkan shard id nya
 - Headphones memiliki product id = 3



Mentee: Yovina Silvia Mentor: Bilal Benefit



```
FROM products
WHERE name = 'Headphones'
)
SELECT
product_shards.product_id,
product_shards.shard_id,
product_placements.node_name
FROM product_shards
INNER JOIN product_placements
ON product_placements.shard_id = product_shards.shard_id;
```

Skrip SQL ini bertujuan untuk menemukan lokasi fisik (node) dari shard yang menyimpan informasi tentang produk tertentu (dalam hal ini, 'Headphones') di dalam kluster Citus yang terdistribusi.

> CTE product placements

- o **pg_dist_shard_placement**: Ini adalah tabel sistem Citus yang menyimpan informasi tentang penempatan shard, termasuk ID shard dan nama node di mana shard tersebut ditempatkan.
- o CTE product_placements: Common Table Expression (CTE) ini memilih shardid dan nodename, mengganti nama kolom menjadi shard_id dan node_name untuk digunakan nanti.

> CTE product shards

- o **products**: Tabel products berisi informasi produk seperti product_id, name, dan price.
- o **get_shard_id_for_distribution_column**: Fungsi Citus yang mengambil ID shard untuk kolom distribusi tertentu. Dalam hal ini, kolom distribusi adalah product id dari tabel products.
- o CTE product_shards: CTE ini memilih product_id, menghitung shard_id menggunakan get_shard_id_for_distribution_column, dan membuat nama tabel nyata (real_table_name) untuk produk dengan nama 'Headphones'.

Query Utama

- o product shards: CTE dari langkah sebelumnya yang berisi product id, shard id, dan real table name untuk produk 'Headphones'.
- o **product_placements**: CTE dari langkah pertama yang berisi shard_id dan node_name.

Mentee: Yovina Silvia Mentor: Bilal Benefit



o INNER JOIN: Menggabungkan product_shards dengan product_placements berdasarkan shard_id, sehingga menghubungkan informasi produk dengan lokasi fisiknya di kluster.

Query ini menghasilkan:

- product_id: ID dari produk 'Headphones'.
- shard_id: ID dari shard yang menyimpan data tentang produk 'Headphones'.
- **node name**: Nama node di kluster Citus tempat shard tersebut disimpan.
- Product Headphones tersimpan di node name:

citus-demo_worker_1, citus-demo_worker_2, dan citus-demo_worker_3

Mentee: Yovina Silvia Mentor: Bilal Benefit



4. Di node/worker mana saja order dengan id 13 tersimpan? Tunjukkan shard id nya

```
WITH order_placements AS (
    SELECT
   FROM pg dist shard placement
order shards AS (
   SELECT
       get_shard_id_for_distribution_column('orders', order_id) as shard_id,
        'orders_' || get_shard_id_for_distribution_column('orders', order_id) as real_table_name
   FROM orders
   WHERE order id = 13
SELECT
   order shards.order id,
   order shards.shard id,
   order placements.node name
FROM order_shards
INNER JOIN order placements
   ON order placements.shard id = order shards.shard id;
```

Skrip SQL ini bertujuan untuk menemukan lokasi fisik (node) dari shard yang menyimpan informasi tentang pesanan tertentu (dalam hal ini, order id 13) di dalam kluster Citus yang terdistribusi.

- > CTE order_placements
 - o **pg_dist_shard_placement**: Ini adalah tabel sistem Citus yang menyimpan informasi tentang penempatan shard, termasuk ID shard dan nama node di mana shard tersebut ditempatkan.
 - o CTE order_placements: Common Table Expression (CTE) ini memilih shardid dan nodename, mengganti nama kolom menjadi shard id dan node name untuk digunakan nanti.

Mentee: Yovina Silvia Mentor: Bilal Benefit



CTE order_shards

- o orders: Tabel orders berisi informasi pesanan seperti order_id, user_id, total_price, dan created_at.
- o **get_shard_id_for_distribution_column**: Fungsi Citus yang mengambil ID shard untuk kolom distribusi tertentu. Dalam hal ini, kolom distribusi adalah order id dari tabel orders.
- o CTE order_shards: CTE ini memilih order_id, menghitung shard_id menggunakan get_shard_id_for_distribution_column, dan membuat nama tabel nyata (real_table_name) untuk pesanan dengan order_id 13.

> Query Utama

- o order_shards: CTE dari langkah sebelumnya yang berisi order id, shard id, dan real table name untuk pesanan order id 13.
- o order placements: CTE dari langkah pertama yang berisi shard id dan node name.
- o INNER JOIN: Menggabungkan order_shards dengan order_placements berdasarkan shard_id, sehingga menghubungkan informasi pesanan dengan lokasi fisiknya di kluster.

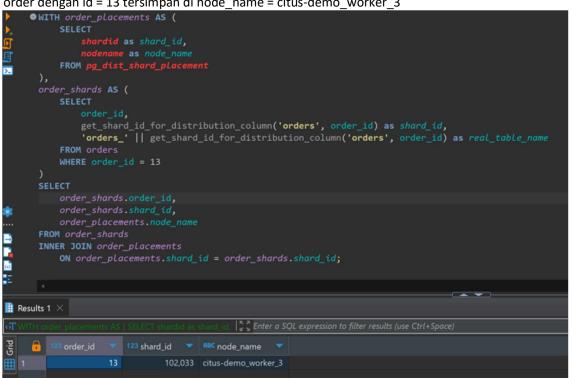
Query ini menghasilkan:

- o **order id**: ID dari pesanan 13.
- o **shard_id**: ID dari shard yang menyimpan data tentang pesanan 13.
- o **node_name**: Nama node di kluster Citus tempat shard tersebut disimpan.

Mentee: Yovina Silvia Mentor: Bilal Benefit



order dengan id = 13 tersimpan di node name = citus-demo worker 3



Mentee: Yovina Silvia Mentor: Bilal Benefit



5. Kapan sebaiknya kita menggunakan replication?

Replication:

- Digunakan ketika memerlukan ketersediaan data yang tinggi dan pemulihan bencana.
- Cocok untuk aplikasi yang memerlukan load balancing untuk query baca.
- Digunakan pada sistem yang memerlukan toleransi kesalahan dan uptime tinggi.

6. Kapan sebaiknya kita menggunakan sharding?

Sharding:

- Digunakan ketika volume data sangat besar dan memerlukan skalabilitas tinggi.
- Cocok untuk aplikasi dengan beban kerja baca dan tulis yang tinggi.
- Digunakan pada sistem yang memerlukan pemrosesan data cepat dan kapasitas penyimpanan yang luas.